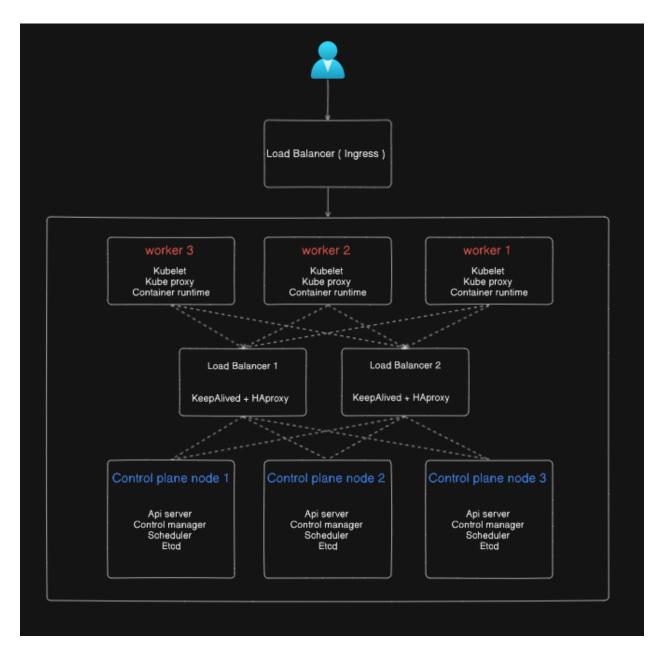
# Highly Available Kubernetes Cluster



C'est quoi Kubernetes?

Kubernetes (ou K8s pour les intimes), c'est comme un chef d'orchestre qui gère des applications sur plein de machines.

Tu veux lancer une appli ? Il la déploie, la surveille, redémarre si elle tombe, et s'occupe de la faire tourner là où il y a de la place.

#### C'est quoi un cluster Kubernetes?

Un cluster, c'est un groupe de machines (physiques ou virtuelles) qui bossent ensemble pour héberger des applications.

- Y'a des chefs (masters) qui pilotent
- Et des **ouvriers (workers)** qui font tourner les applications

#### Pourquoi utiliser un cluster multi-nœuds hautement disponible?

Pour éviter que tout plante si une machine tombe en panne.

Avec plusieurs nœuds, Kubernetes peut continuer à fonctionner même si une partie du cluster a un souci.

Disponibilité continue, résilience, et scalabilité.

#### Les composants du master node (plan de contrôle)

Ce sont les cerveaux du cluster :

- API Server : La porte d'entrée, c'est lui qui reçoit toutes les commandes.
- Scheduler : Il décide où lancer les applications.
- Controller Manager: Il surveille que tout fonctionne bien.
- etcd : C'est la base de données du cluster (état global du système).

### Les composants des worker nodes (nœuds de travail)

Ce sont les muscles :

- Kubelet : Il suit les ordres du master.
- Kube-proxy : Il gère le réseau.

• Runtime de conteneur (comme Docker) : Il fait tourner les applis.

#### # HAProxy et Keepalived, c'est quoi?

- HAProxy : répartit les requêtes entre les serveurs de contrôle (kube-apiserver).
- Keepalived : fournit une IP virtuelle → si une machine tombe, une autre prend le relais automatiquement.

#### ? Pourquoi 3 nœuds master ? Pas 1, ni 2 ?

C'est quoi un quorum?

Un **quorum**, c'est le **nombre minimum de nœuds** (dans un groupe) qui doivent être **en ligne et d'accord** pour que le système puisse **prendre des décisions** (écrire, élire un leader, etc.)

**©** En Kubernetes, le quorum est utilisé par etcd, la base de données des masters.

#### Formule du quorum :

quorum = (nombre total de nœuds / 2) + 1

- Le quorum est toujours une **majorité**.
- Sans quorum, etcd est bloqué → donc le cluster Kubernetes est figé!

#### Différence entre 2 masters et 3 masters

Cas	Nombre total de masters	Quorum requis	Tolérance aux pannes
🗶 2 masters	2	2	0 (aucune panne possible)
✓ 3 masters	3	2	1 panne possible

#### Exemple avec 2 nœuds masters

master1 et master2

- Quorum = 2
- Si 1 tombe, il ne reste qu'un seul nœud → quorum non atteint X
  - Cluster bloqué même s'il te reste un master

#### Exemple avec 3 nœuds masters

- master1 , master2 , master3
- Quorum = 2
- Si 1 tombe (peu importe lequel), il reste 2 nœuds → quorum ok
  - Cluster continue à fonctionner normalement

#### O'est quoi l'Ingress?

L'Ingress est comme un portier d'hôtel . Il gère les routes HTTP (ex: /admin , /app ) et les redirige vers les bonnes applis.

#### Exemple :

www.monsite.com/admin  $\rightarrow$  Pod A www.monsite.com/shop  $\rightarrow$  Pod B

#### Comment un utilisateur accède à l'application ?

- 1. Il tape une URL (ex: myapp.com)
- 2. Le load balancer externe redirige vers l'Ingress
- 3. L'Ingress envoie la requête vers le bon pod (ex: application Joget)
- 4. Le pod répond → l'utilisateur voit son interface

#### Aider un DevOps à configurer les VM (pour Joget + DB)

Voici une proposition simple et réaliste :

Rôle VM	CPU	RAM	Stockage	Détails
Master Node (x3)	2	2 Go	40 Go	etcd + control plane

Worker Node (x2+)	4	8 Go	60 Go	Joget + apps
Base de données (DB)	4	8 Go	60 Go	MySQL/Postgres
Load Balancer (x2)	1	1 Go	20 Go	HAProxy + Keepalived
NFS Server (option)	1	2 Go	100 Go	Stockage partagé

## Les 3 Load Balancers dans ton cluster Kubernetes HA:

#### 1. **(f)** Load Balancer Externe

- Rôle: Point d'entrée pour les utilisateurs finaux (navigateur, mobile, API, etc.)
- IP publique/virtuelle : ex. 192.168.1.100 OU myapp.company.com
- **Redirige vers**: les 2 load balancers internes (HAProxy)
- Souvent géré par : Keepalived (pour failover) + floating IP

### 2. Load Balancer Interne 1 (HAProxy 1) et Interne 2 (HAProxy 2)

- Rôle : répartissent le trafic vers les kube-apiserver des 3 nœuds de contrôle
- Ils sont en redondance grâce à Keepalived
- Ils assurent que le plan de contrôle reste disponible même si un LB interne tombe

### **Comment fonctionne un cluster Kubernetes avec plusieurs masters ?**

Dans une architecture **multi-masters**, plusieurs serveurs (nœuds de contrôle) hébergent chacun une copie des composants critiques de Kubernetes (kube-apiserver, etcd, scheduler, etc.).

Cela permet au cluster de continuer à fonctionner même si un ou deux masters tombent en panne. C'est le principe de la haute disponibilité (HA).

#### Pourquoi faut-il un Load Balancer interne?

Le Load Balancer interne agit comme un **point d'entrée unique** vers les kubeapiserver répartis sur les masters.

Tous les composants (kubelet, kubectl, etc.) communiquent avec **cette seule adresse** (ex: 192.168.193.135:6443), sans se soucier de quel master est actif.

#### Ses avantages :

- Répartit le trafic entre les masters
- 💥 Si un master tombe, les autres prennent le relais automatiquement
- 🧩 Simplifie la configuration : une seule IP pour accéder au cluster

#### X Et si on n'en met pas?

#### Sans Load Balancer:

- Tu dois taper manuellement sur les IPs des masters
- Pas de bascule automatique en cas de panne
- Le cluster devient fragile et perd le bénéfice de la haute dispo